

UNIVERSIDAD TÉCNICA ESTATAL DE QUEVEDO

Facultad de Ciencias de la Computación

Carrera de Ingeniería de Software

Asignatura: Ingeniería de Requerimientos (ISR-401)

Protocolo experimental

Detección automática de ambigüedad y malos olores en requisitos

Proyecto:	FabroGym - Sistema de gestión administrativa y operativa para un gimnasio
Entrega:	Entrega 3 (2A) - componente empírico
Enfoque seleccionado:	Enfoque 2 - detección automática de ambigüedad y malos olores en requisitos
Versión:	1.0 - paquete reproducible para prerregistro
Fecha:	2 de agosto de 2026
Repositorio:	https://github.com/amorad35/FabroGym_ISR401
Estado:	Borrador preparado; no ejecutado y sin registro OSF definitivo

Equipo PFC - Gimnasio

Alvia Villegas Erick Adalberto	Analista líder / entrevistador
Mera Arias Erick Jhair	Documentador / responsable de encuestas
Mora Duarte Alex José	Modelador / apoyo de análisis
Ponce Rivera Mery Helenmey	Verificadora / calidad de requisitos
Vaca Romero David Octavio	Apoyo documental / evidencias

Índice

1. Control de versión y condición de uso	3
2. Resumen	3
3. Antecedentes y justificación	3
4. Objetivos	3
4.1. Objetivo general	3
4.2. Objetivos específicos	3
5. Preguntas de investigación y PICOC	4
6. Hipótesis	4
7. Variables	4
8. Diseño del estudio	5
8.1. Participantes	5
8.2. Tamaño muestral estimado	5
9. Instrumentos	5
10. Procedimiento	6
11. Plan de análisis	6
11.1. Preparación y calidad	6
11.2. Consenso y acuerdo	6
11.3. Desempeño del detector	6
11.4. Análisis de desacuerdos	6
12. Ética y gestión de datos	6
13. Amenazas a la validez	7
14. Productos reproducibles	7
15. Cronograma	7
16. Lista de control previa al inicio	7

1. Control de versión y condición de uso

Estado real del estudio. Este documento es una base completa para revisión, aprobación ética y preregistro. El experimento no debe ejecutarse sobre los 25 requisitos reales, ni deben recopilarse evaluaciones expertas, hasta que el protocolo haya sido registrado formalmente en OSF y se haya guardado el comprobante con fecha anterior a la ejecución. Los archivos de resultados incluidos en el paquete son plantillas vacías y no contienen datos inventados.

Versión	Fecha	Cambio
1.0	2026-08-02	Diseño completo del Enfoque 2, corpus de 25 RF, instrumentos, bloqueo pre-OSF y scripts reproducibles.

2. Resumen

El estudio evaluará hasta qué punto un detector automático basado en reglas lingüísticas replica el juicio de personas expertas al identificar ambigüedad y malos olores en los 25 requisitos funcionales vigentes del ERS/SRS de FabroGym. Cada requisito será clasificado de forma independiente por al menos tres evaluadores y por el detector. El consenso experto se utilizará como referencia para calcular precisión, exhaustividad y medida F1. También se calcularán los coeficientes kappa de Cohen entre pares y kappa de Fleiss para el conjunto de evaluadores. Los desacuerdos se analizarán de forma cualitativa y se conservará una cadena reproducible desde el archivo fuente hasta las tablas y figuras.

3. Antecedentes y justificación

El ERS/SRS consolidado contiene 25 requisitos funcionales en español con trazabilidad a evidencia de campo. La guía de la Entrega 3 (2A) permite seleccionar un estudio de detección automática de ambigüedad y malos olores, comparando la salida de una herramienta con el juicio independiente de por lo menos tres personas. Este enfoque resulta coherente con FabroGym porque el ERS excluye componentes de IA o aprendizaje automático y ya dispone del corpus mínimo de 25 RF necesario para una evaluación moderada.

El detector no se presenta como sustituto de la revisión humana. Su propósito es identificar candidatos a revisión mediante reglas transparentes y reproducibles. Una marca del detector significa “posible smell”, no demuestra por sí sola que el requisito sea incorrecto.

4. Objetivos

4.1. Objetivo general

Evaluar la capacidad de un detector automático basado en reglas para identificar requisitos funcionales ambiguos en el corpus FabroGym, utilizando como referencia el consenso de evaluadores independientes.

4.2. Objetivos específicos

1. Construir una línea base reproducible con los 25 RF de la versión 1.5.8 del ERS/SRS.
2. Clasificar los requisitos con un detector de smells lingüísticos y con al menos tres evaluadores independientes.
3. Calcular precisión, exhaustividad, F1, matriz de confusión y acuerdo inter-evaluador.
4. Analizar los desacuerdos por tipo de smell y documentar amenazas a la validez.

5. Generar tablas y figuras exclusivamente mediante scripts versionados.

5. Preguntas de investigación y PICOC

ID	Pregunta de investigación	Respuesta operacional
RQ1	¿Con qué precisión un detector automático replica el consenso experto al identificar RF ambiguos?	Precisión, exhaustividad, F1, exactitud, matriz de confusión e intervalo bootstrap del 95 %.
RQ2	¿Qué nivel de acuerdo existe entre las personas evaluadoras?	Kappa de Cohen por pares y kappa de Fleiss global.
RQ3	¿Qué smells y tipos de desacuerdo aparecen con mayor frecuencia?	Frecuencias por categoría, falsos positivos, falsos negativos y notas de adjudicación.

Población	Veinticinco requisitos funcionales del ERS/SRS FabroGym v1.5.8, redactados en español.
Intervención	Detector automático transparente basado en patrones y expresiones regulares.
Comparación	Clasificación por consenso mayoritario de al menos tres evaluadores independientes.
Resultado	Precisión, recall, F1, acuerdo inter-evaluador, frecuencia de smells y análisis de desacuerdos.
Contexto	Proyecto académico de Ingeniería de Requerimientos ISR-401, dominio de gestión administrativa de gimnasios.

6. Hipótesis

H0-1. No existe diferencia estadísticamente significativa entre las proporciones pareadas de clasificación positiva del detector y del consenso experto.

H1-1. Existe diferencia estadísticamente significativa entre ambas proporciones. La prueba prevista es McNemar, bilateral, con $\alpha = 0,05$.

H0-2. El acuerdo global entre evaluadores no supera el esperado por azar ($\kappa \leq 0$).

H1-2. El acuerdo global entre evaluadores supera el esperado por azar ($\kappa > 0$).

El valor F1 de 0,70 se utilizará como umbral práctico de utilidad preliminar, no como sustituto de las pruebas estadísticas ni como garantía de calidad.

7. Variables

Tipo	Variable	Operacionalización
Independiente	Método de clasificación	Detector automático o evaluación humana independiente.
Dependiente	Etiqueta de ambigüedad	0 = no ambiguo; 1 = ambiguo.
Dependiente	Rendimiento del detector	Precisión, recall, F1, exactitud y matriz de confusión frente al consenso.
Dependiente	Acuerdo experto	Kappa de Cohen y kappa de Fleiss.
Dependiente	Tipo de smell	SM-01 a SM-08 según la rúbrica instrumental.

Tipo	Variable	Operacionalización
Control	Corpus y versión	Mismos 25 RF congelados desde el archivo fuente y el commit declarado en OSF.
Control	Instrucciones	Misma guía, rúbrica, tiempo y formato para todas las personas evaluadoras.
Control	Independencia	Las personas evaluadoras no ven la salida del detector ni las respuestas de otras personas.
Control	Reproducibilidad	Versión de Python, dependencias, semilla y versión del detector fijadas.

8. Diseño del estudio

Se utilizará un estudio de exactitud diagnóstica con observaciones pareadas por requisito. La unidad de análisis es cada RF. El corpus mínimo es de 25 unidades. La referencia se construirá mediante mayoría simple de por lo menos tres evaluadores. Si existe empate por incorporación de un número par de evaluadores, se realizará una adjudicación documentada por una persona adicional que no haya visto la salida del detector.

8.1. Participantes

Mínimo: tres evaluadores independientes; **recomendado:** cinco. Se aceptarán docentes, profesionales o estudiantes avanzados que hayan cursado Ingeniería de Requerimientos y puedan justificar experiencia en revisión de requisitos.

Criterios de inclusión: mayoría de edad; aceptación del consentimiento; conocimiento básico de RF, verificabilidad y ambigüedad; ausencia de participación directa en la redacción del corpus.

Criterios de exclusión: integrante del equipo FabroGym; conocimiento previo de la salida del detector; evaluación incompleta de más del 10 % del corpus; retiro voluntario.

8.2. Tamaño muestral estimado

La muestra de unidades se fija en los 25 RF del ERS/SRS v1.5.8. La muestra humana mínima será de tres evaluadores independientes y se recomiendan cinco. El tamaño está determinado por el corpus obligatorio y por la réplica moderada propuesta en la guía; por ello no se realizará inferencia a una población abierta de requisitos ni de profesionales.

No se realizará cálculo de potencia basado en población humana porque la unidad de análisis principal son los 25 RF fijados por la guía. Se reportará esta limitación y se usarán intervalos bootstrap para las métricas del detector.

9. Instrumentos

1. Corpus de 25 RF: `fuentes/requisitos_fabrogym_v1.5.8.csv`.
2. Guía para evaluadores: `instrumentos/01_Guia_Evaluacion_Expertos.pdf`.
3. Consentimiento actualizado: `instrumentos/02_Plantilla_Consentimiento_Evaluador.pdf`.
4. Rúbrica operacional: `instrumentos/04_Rubrica_Evaluacion_Experta.csv`.
5. Matriz de captura: `instrumentos/03_Matriz_Evaluacion_Expertos.csv`.
6. Detector y análisis: `archivos de scripts_analisis/`.

10. Procedimiento

1. Revisar este protocolo con el equipo y el docente; declarar el enfoque 2 en la adenda ética.
2. Crear el registro OSF, adjuntar el protocolo y fijar el commit del corpus y scripts.
3. Guardar el comprobante real como `06_Experimento/osf_registration.pdf`.
4. Confirmar que la fecha del registro sea anterior a toda evaluación y a la ejecución del detector sobre el corpus real.
5. Reclutar al menos tres evaluadores, obtener el consentimiento y asignar códigos EXP-01, EXP-02, etc.
6. Entregar la guía, la rúbrica y los RF en orden aleatorizado. Cada evaluación se realiza de forma independiente.
7. Ejecutar el detector con la versión y semilla declaradas en OSF.
8. Consolidar la mayoría experta sin mostrar la salida automática durante la adjudicación.
9. Ejecutar `python scripts_analisis/run_all.py` para producir tablas y figuras.
10. Revisar los desacuerdos y redactar resultados sin extrapolar más allá del corpus.

11. Plan de análisis

11.1. Preparación y calidad

Se validarán duplicados, valores permitidos, cobertura de los 25 RF y consistencia de IDs. Las evaluaciones incompletas se documentarán. No se imputarán etiquetas de ambigüedad. La prueba Shapiro–Wilk, las pruebas *t*/Wilcoxon y los tamaños de efecto Cohen *d*/Cliff δ no se aplican a la comparación binaria principal de este Enfoque 2. La discrepancia pareada se evaluará con McNemar y el desempeño con métricas diagnósticas e intervalos bootstrap. Cualquier variable continua auxiliar deberá definirse antes del prerregistro.

11.2. Consenso y acuerdo

El consenso será mayoría simple. Se calculará kappa de Cohen para cada par y kappa de Fleiss global. Se reportarán valores, número de evaluadores y distribución de categorías, sin convertir las bandas interpretativas en reglas absolutas.

11.3. Desempeño del detector

Se calcularán verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos; precisión, recall, F1 y exactitud; intervalos bootstrap del 95 % con semilla fijada; y prueba exacta de McNemar para la discrepancia pareada. La prueba Shapiro–Wilk no se aplicará a las etiquetas binarias. Solo se usaría sobre una variable continua auxiliar si esta se incorpora antes del prerregistro.

11.4. Análisis de desacuerdos

Cada falso positivo y falso negativo se revisará contra la rúbrica. Se registrará la categoría de smell, la razón del desacuerdo y la decisión de mejora del detector o del requisito. RQ3 se responderá de forma descriptiva.

12. Ética y gestión de datos

Las personas evaluadoras recibirán información sobre finalidad, voluntariedad, retiro y uso académico. Sus nombres, firmas, correos y consentimientos originales permanecerán en la zona restringida cifrada. En

la zona pública solo se utilizarán códigos EXP-NN y evaluaciones sin identificadores. No se recopilarán datos de salud, biometría ni información de clientes del gimnasio.

El conjunto anonimizado, el protocolo y los resultados se prepararán para licencia CC BY 4.0. Los scripts podrán conservar la licencia definida por el repositorio. La tabla que vincule códigos con identidades, si se crea, no se publicará.

13. Amenazas a la validez

Constructo: las reglas detectan señales textuales, no ambigüedad semántica completa.

Interna: experiencia desigual entre evaluadores y posible fatiga. Se mitiga con instrucciones uniformes, orden aleatorizado e independencia.

Externa: corpus pequeño, un solo proyecto, dominio de gimnasio y lengua española. No se generalizará a todos los sistemas.

Conclusión: métricas inestables ante pocos positivos. Se reportarán conteos e intervalos bootstrap.

Reproducibilidad: cambios posteriores en RF o reglas. Se mitiga declarando versión, hash, commit, dependencias y semilla.

14. Productos reproducibles

- Datos fuente y plantillas CSV con diccionario en los README.
- Código de detector y análisis con ejecución única mediante `run_all.py`.
- Tablas CSV y figuras PNG/SVG generadas desde datos crudos.
- Registro OSF inmutable anterior a la ejecución.
- Historial de cambios y hashes SHA-256 incorporados al repositorio general.

15. Cronograma

Etapas	Actividad
Preparación	Revisión del protocolo, instrumentos, adenda ética y corpus.
Prerregistro	Registro OSF y archivo del comprobante.
Recolección	Consentimiento y evaluación independiente de expertos.
Ejecución	Aplicación del detector al corpus congelado.
Análisis	Cálculo de métricas, acuerdo, desacuerdos, tablas y figuras.
Reporte	Integración de resultados y discusión en Entrega 4.

16. Lista de control previa al inicio

- ☐ Enfoque 2 declarado en la adenda ética.
- ☐ Protocolo revisado por el equipo y docente.
- ☐ Registro OSF enviado y aprobado.
- ☐ URL persistente y sello temporal guardados.
- ☐ Commit y SHA-256 del corpus congelados.
- ☐ Consentimiento e instrumentos definitivos.
- ☐ Al menos tres evaluadores elegibles.
- ☐ Detector no ejecutado sobre el corpus real antes del registro.

Referencias

- [1] Facultad de Ciencias de la Computación, UTEQ, *Guía y rúbrica de evaluación - Entrega 3 (2A)*, 2026.
- [2] C. Wohlin et al., *Experimentation in Software Engineering*. Springer, 2012.
- [3] A. Jedlitschka, M. Ciolkowski y D. Pfahl, “Reporting experiments in software engineering,” 2008.
- [4] B. A. Nosek et al., “The preregistration revolution,” *PNAS*, vol. 115, no. 11, pp. 2600–2606, 2018.
- [5] J. Cohen, “A coefficient of agreement for nominal scales,” *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [6] J. L. Fleiss, “Measuring nominal scale agreement among many raters,” *Psychological Bulletin*, vol. 76, no. 5, pp. 378–382, 1971.
- [7] A. Ferrari, P. Spoletini y S. Gnesi, “Ambiguity and tacit knowledge in requirements elicitation interviews,” *Requirements Engineering*, vol. 21, no. 3, pp. 333–355, 2016.
- [8] ISO/IEC/IEEE, *ISO/IEC/IEEE 29148:2018 - Requirements Engineering*, 2018.